

# El uso del web scraping para la extracción de datos

26/01/2021

# Equipo: "Las mágicas FCC"

- → Amador González Angélica
- → Goiz De Jesús Nancy Guadalupe
- → González Sartillo Luis Gustavo
- → Guzmán Meza Deisy de los Angeles
- → Reyes Reyes María Maribel
- → Valerio Vargas Belén

## **ÍNDICE**

Introducción

Visión general

**Objetivos** 

**Especificaciones** 

Planteamiento del problema

Diagrama o modelo

Metodología PMBOK

Base de datos

Conclusión

# **INTRODUCCIÓN**

Vivimos en una era digital donde las necesidades de las personas no se limitan por el lugar donde viven, esto da lugar a varias propuestas innovadoras. Cada día la tecnología se va abriendo paso para reemplazar tareas cotidianas, así como el trabajo monótono. Hoy en día, un ingeniero en computación es necesario para desarrollar soluciones que reemplace el trabajo monótono o que no puede ser pagado, ya sea porque no se encuentra el personal adecuado o porque la empresa no tiene los recursos necesarios para cubrir las necesidades.

En este informe redactamos nuestro trabajo realizado en la extracción de datos con Web Scraping para el análisis de precios en el mercado, así como las dificultades que se nos presentaron.

#### **Web Scraping**

Es una técnica utilizada mediante programas de software para extraer información de sitios web. Usualmente, estos programas simulan la navegación de un humano en la World Wide Web ya sea utilizando el protocolo HTTP manualmente, o incrustando un navegador en una aplicación. El web scraping está muy relacionado con el registro de la web, la cual indexa la información de la web utilizando un robot y es una técnica universal adoptada por la mayoría de los motores de búsqueda. Sin embargo, el web scraping se enfoca más en la transformación de datos sin estructura en la web (como el formato HTML) en datos estructurados que pueden ser almacenados y analizados en una base de datos central, en una hoja de cálculo o en alguna otra fuente de almacenamiento. El término web scraping también está relacionado con la automatización de tareas en la Web, la cual simula la navegación de un humano utilizando un software de computadora. Algunos de los usos del web scraping son: la comparación de precios en tiendas, la monitorización de datos relacionados con el clima de cierta región, la detección de cambios en sitios webs y la integración de datos en sitios webs. También es utilizado para obtener información relevante de un sitio a través de los rich snippets.

# Visión general

La idea central es hacer uso de web Scraping para analizar una o varias páginas de internet y a partir de ahí extraer información y todo lo que conlleva el trabajo del proyecto (extracción de datos) y a partir de ese punto tratamiento de la información, se puede hacer el análisis de varias páginas. Todo esto con la finalidad de obtener datos de productos específicos de 3 tiendas online y con ello poder hacer comparaciones y estadísticas que nos mostrarán información útil como:

¿Cuál fue el producto más vendido?

¿En qué tienda se puede encontrar el producto con las mismas características pero más barato?

# **Objetivos**

#### General

Extraer datos de páginas de comercio electrónico mediante Web Scraping y aplicar técnicas de tratamiento de la información.

#### Específico

- 1. Analizar la información de los diferentes productos en páginas de comercio electrónico.
- 2. Almacenar y clasificar datos de acuerdo a precios, tendencias y demandas de los productos ofrecidos en el comercio electrónico.
- 3. Desarrollar una aplicación web que permita al consumidor hacer compras inteligentes mediante la comparación de precios, marcas y proveedores.

## **Especificaciones**

El proyecto consta de 4 pasos fundamentales, los cuales nos ayudarán a tener una visión más clara.

- 1.- La extracción o raspado (scraping) de diferentes páginas web, esto para recopilar y ubicar de manera automática y eficiente la información de diferentes productos que podamos llegar a identificar como "importantes" para el desarrollo.
- 2.- El proceso de almacenamiento pos extracción consiste en buscar una alternativa para recopilar y tener almacenada de manera "ordenada" nuestra información de utilidad, es decir; al término del proceso de scraping, podemos guardar en diferentes formatos nuestra información (csv, arff, xml, sql etc).

- 3.- Una vez creada nuestra propia base de datos, con las diferentes fuentes de información, podemos proceder al proceso de tratamiento de la información, de manera detallada, se observará, analizará y pulirá esta información, para visualizar posibles tendencias de ciertos productos, y responder de manera manual, diferentes preguntas que vayan surgiendo.
- 4.- Al concluir los procesos del punto anterior, podemos realizar una aplicación, la cual tiene como utilidad, mostrar a un usuario, diferentes tipos de consulta, es decir; si queremos ver que producto es más vendido en "X" tienda o que producto es más barato, y donde posiblemente puede convenirle la compra, esta aplicación, con ayuda de esa base de datos, puede mostrar dicha información, sin necesidad de visitar diferentes páginas web de compras.

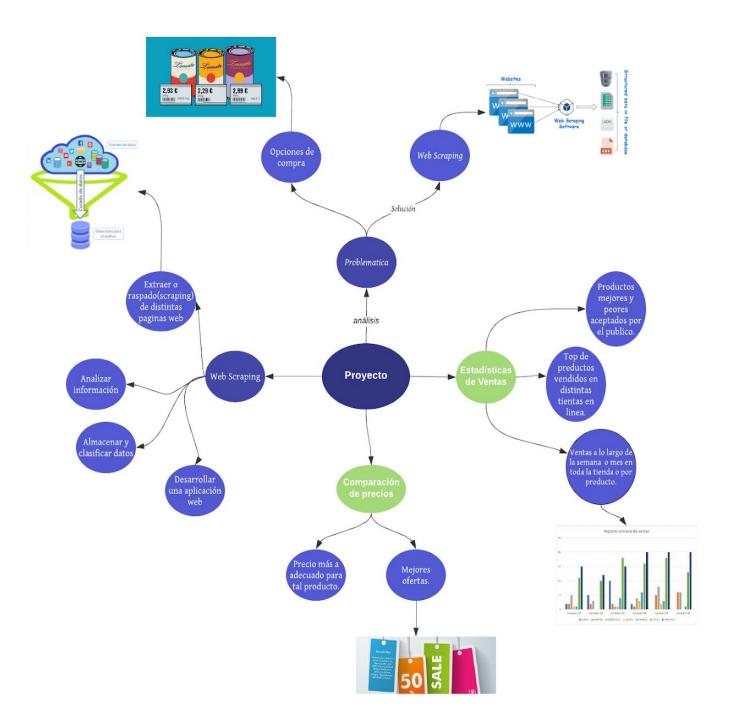
# Planteamiento del problema

Actualmente el comercio por línea ha incrementado notablemente, sin embargo, al buscar nuestro producto encontramos varias alternativas en las páginas de internet como lo son el precio y calidad. Para elegir la mejor opción de compra requerimos navegar por las distintas páginas que ofrecen el producto, esto ocasiona cambiar de pestaña constantemente, o bien, abrir múltiples pestañas para poder comparar las opciones.

El web scraping nos permitirá la extracción de información, que siguiendo las especificaciones antes mencionadas, abrirán paso a una aplicación donde el comparar productos sea más sencillo, reduciendo tiempos de búsqueda y navegación.

Con este proyecto se busca que los usuarios de nuestra plataforma tengan una visión resumida de las opciones de compra que tiene su producto. Además, los usuarios que se encontraban desinformados de las distintas formas de usar el internet como lo es el comercio electrónico se verían motivados a comprar por este medio.

# Diagrama



# Metodología PMBOK

Gestionar los proyectos no es algo que parta de la improvisación de los responsables, es necesario partir de procesos establecidos, herramientas y estándares de esta forma los macroprocesos ayudan a organizar las necesidades que pueden tener cualquier organización, independientemente del rubro.

#### ¿ Qué es la guía del PMBOK?

La Guía de los Fundamentos para la Dirección de Proyecto (Guía del PMBOK) es una norma norteamericana muy reconocida en el campo de la gestión de proyectos al punto que es adoptada en muchos países.

La guía PMBOK identifica 5 macroprocesos en los que se incluyen los 47 procesos estándares que intervienen en cualquier proyecto:

- ➤ Inicio: conformado por 2 procesos menores, cuyo fin es definir un nuevo proyecto o una nueva fase de ejecución del mismo, y obtener la autorización necesaria para llevarlo a cabo.
- Planificación: este macroproceso incluye 24 procesos destinados a la concreción y el establecimiento de objetivos, y al diseño de las estrategias más adecuadas para lograr su consecución.
- **Ejecución**: incluye **8 procesos implicados en el correcto desempeño,** acorde a la estrategia adoptada, de las actividades definidas en el proyecto para la consecución de los fines establecidos.
- > Control y monitorización: once procesos se inscriben en este macroproceso, todos ellos relacionados con la supervisión y la evaluación del desempeño del proyecto.
- Cierre: último macroproceso, formado por dos procesos menores, que cierra el proyecto en su totalidad o alguna fase del mismo refiriendo el grado de aceptación y la satisfacción con el resultado obtenido.

Todo proceso se ejecuta por lo menos una vez en cada proyecto y en una o más fases del proyecto (Eso es lo que señala el Pmbok) en el caso de la gestión de riesgos hay elementos que serán importantes tanto para considerar la situación del proyecto como la respuesta a los escenario no deseados.

Las 10 etapas iniciales que nos aclara la quía de gestión de riesgos son:

- → Integración del proyecto
- → Gestión del alcance del proyecto
- → Gestión del tiempo del proyecto
- → Gestión de los costes del proyecto
- → Gestión de la calidad del proyecto
- → Gestión de los recursos humanos del proyecto
- → Gestión de las comunicaciones del proyecto
- → Gestión de los riesgos del proyecto
- → Gestión de las adquisiciones del proyecto

→ Gestión de los Interesados del proyecto

#### Conclusiones

Pmbok es una herramienta muy completa y organizada para seleccionar y ejecutar procesos dentro de una organización, tener una lista de procesos que se apliquen a diferentes etapas de nuestra organización es de suma utilidad, así como una serie de requerimientos hará que todos los elementos sigan una forma de trabajo y metodologías que nos llevarán a un mejor desempeño.

#### **Gestor Web**

#### Descriptores:

Nombre del descriptor	Descripción	Detalles
Tienda	Comercio en línea del que se extrajeron los datos	Comercial Mexicana
Área	Departamento del comercio	Frutas
Marca/Producto	Producto que se está considerando para comprar	Nombre de la fruta (plátano, fresa, piña, etc)
Precio	Cantidad monetaria para adquirir el producto	El tipo de cambio en pesos mexicano
Cantidad	Unidad en la que se comercia	Kilogramos (Kg), Pieza (pza) o paquete

#### **Octoparse**

Es una herramienta que permite hacer Web Scraping, de cualquier página web, la aplicación permite crear bases de datos en formato JSON, CBV, .xlsx y HTML.

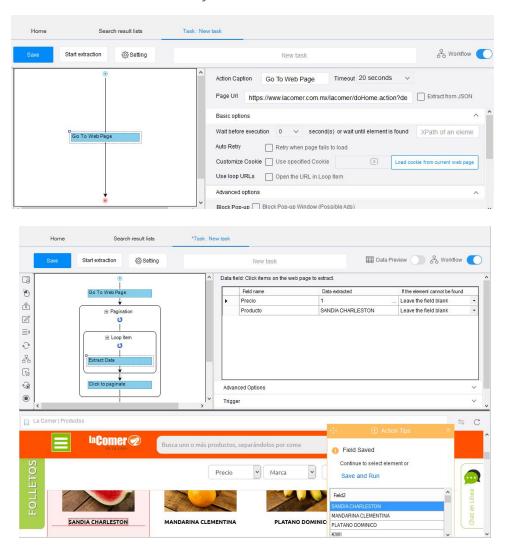
Para acceder a los servicios que la empresa ofrece, es necesario hacer un registro y especificar el fin con el que se pretende usar, en este caso, fines educativos, una vez se complementa el registro se debe descargar e instalar la aplicación de escritorio.

La herramienta trabaja con dos modalidades: Task templates y Advanced Mode, el primer modo ofrece plantillas con algunos descriptores ya preestablecidos, lo que limita la libertad de explorar, para este caso, utilizamos el segundo modo.

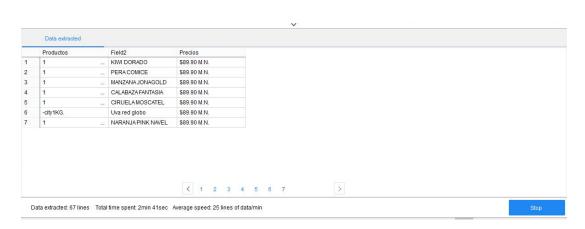
1. Ingresar la URL de la web con la que se trabajará.



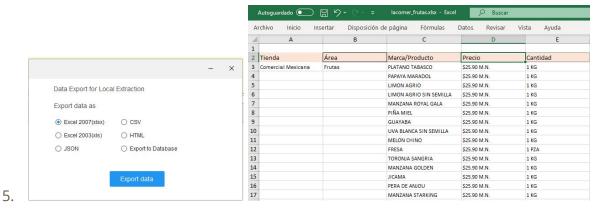
- 2. Crear un bucle de paginación.
  - a. Se especifica el navegador a utilizar (Firefox 45.0)
  - b. Se seleccionan las páginas de los resultados que se van extraer.
  - c. Se seleccionan los datos a extraer (Marca, precio, cantidad).
  - d. Guardar los cambios y comenzar la extracción.



3. Extraer los datos. Tardó alrededor de 6 minutos en sacar 67 filas y 3 columnas.



4. Guardar y exportar la base de datos.

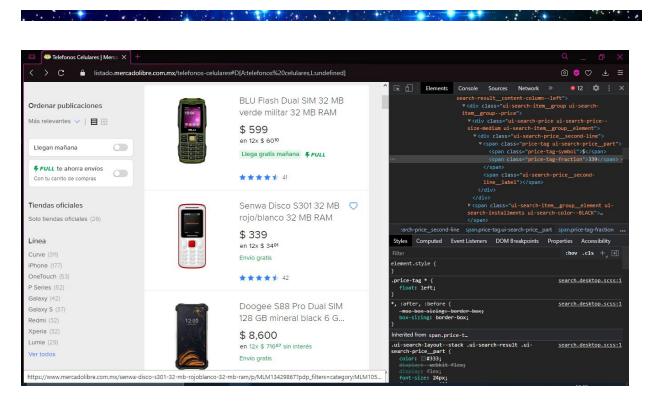


# **Web Scraping con Python**

# **Programa Python (1)**

Para la implementación en python se hizo uso de las librerías de BeautifulSoup (obtener contenido de la página web), request (para mandar solicitudes de nuestro servicio scraping) y pandas (para formatear las listas).

La página que realizó el scraping fue de mercadolibre.com y dentro de la sección de celulares.



Estructuramos nuestros datos y los quardamos en un archivo csv

```
datfra=pd.DataFrame({'Nombre':nombre_equipos, 'Precio': precio}, index=list(range(0,20)))
datfra.to_csv('DataCrawler.csv', index =False )
```

Y así queda nuestra base de datos armada

Α Α	В
Nombre	Precio
BLU Flash Dual SIM 32 MB verde militar 32 MB RAM	599
Senwa Disco S301 32 MB rojo/blanco 32 MB RAM	60
Doogee S88 Pro Dual SIM 128 GB mineral black 6 GB RAM	339
Moto E6 Play 32 GB negro 2 GB RAM	34
Doogee S80 Dual SIM 64 GB negro mineral 6 GB RAM	8,600
Xiaomi Redmi Note 9S Dual SIM 128 GB azul aurora 6 GB RAM	716
Asus ROG Phone 3 ZS661KS Dual SIM 128 GB negro brillante 12 GB RAM	2,749
Asus ZenFone 5 Selfie Pro ZC600KL Dual SIM 64 GB rojo 4 GB RAM	275
Doogee S95 Pro Dual SIM 128 GB negro mineral 8 GB RAM	10,176
Samsung Galaxy A71 128 GB prism crush blue 6 GB RAM	847
iPhone 12 64 GB azul	5,899
Samsung Galaxy A51 128 GB prism crush black 4 GB RAM	591
Senwa Disco S301 32 MB azul/blanco 32 MB RAM	21,998
Alcatel 1066 4 MB negro 4 MB RAM	2,207
N28u Teléfono Móvil De Pantalla Grande De 6.3 Pulgadas.	7,499
R4 Pro + Telé fono Móvil De Pantalla Grande De 6.3 Pulgadas.	752
Teléfono Inteligente 6.3 Pantalla De Gota De Agua De Alta	11,697
16/64/128/512gb Note20 Plus 7.6inch Teléfono De Reconocimien	974
Ulefone Note 7 3g Teléfono Móvil 6.1 Pulgadas 19:9 16 Gb R	7,703
I Teléfono Celular Alcatel 3078 Inteligente BÃisico, Economico 2	772
→ DataCrawler ⊕	

Conclusiones:

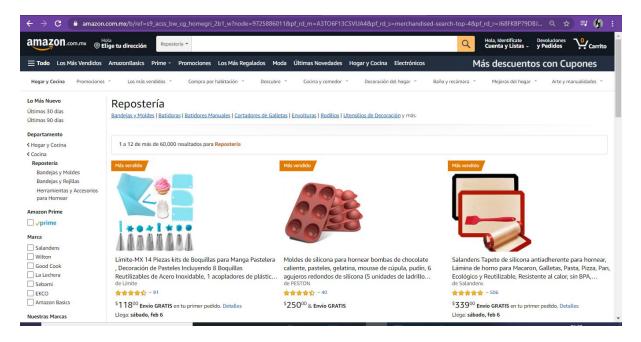
El uso de un programa desarrollado en python es una manera práctica de tener controlado el tipo de formato y un proceso aún más automatizado, la desventaja de esto, es conocer al 100% las etiquetas de los elementos que nosotros queremos extraer.

# **Programa Python (2)**

El web scraping con python es posible gracias a la librerías :

- BeautifulSoup que nos permite extraer contenido de ficheros HTML y XML.
- Request nos facilita enormemente el trabajo con peticiones HTTP(extraer información de una página o enviar el contenido de un formulario de manera automatizada)
- Pandas proporciona estructuras de datos similares a los dataframes, además proporciona herramientas que permiten leer y escribir datos en diferentes formatos: CSV, Microsoft Excel, bases SQL y formato HDF5.

Utilizando estas herramientas se procedió a crear un código que nos permitió recuperar datos de la página amazon.com.mx que continuación se muestra:

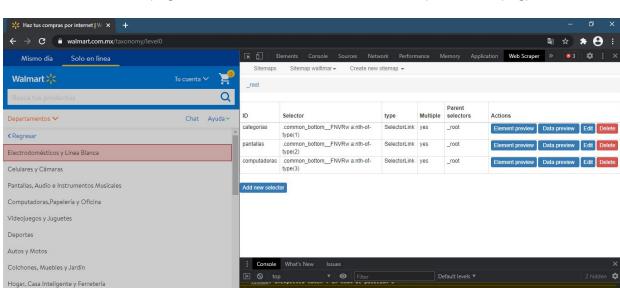


Utilizamos el siguiente código para recabar la información

Posteriormente mostramos el archivo generado del scraping.

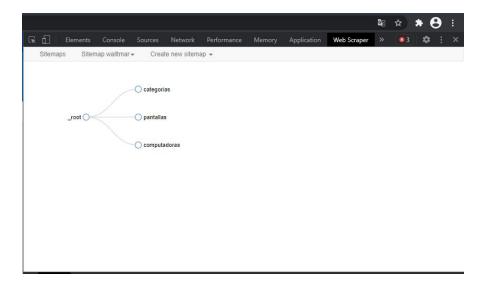
Como podemos observar el web scraping es una de las mejores maneras de obtener datos de alguna página web, ya que facilita la extracción de los mismos, ayudándonos a organizar de mejor manera nuestras bases de datos para análisis posteriores.

## Uso de la extensión de google Chrome



Para la técnica de web scraping usamos una herramienta externa de chrome (free web scraping).

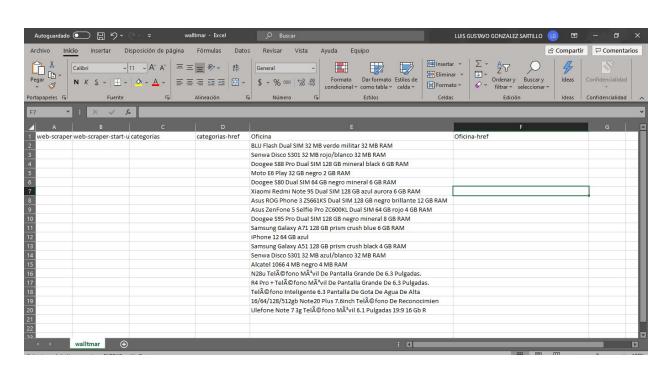
Para el uso de esta herramienta es ir creando "sitemaps" del sitio e ir armando según donde queramos extraer la información.



Moda, Belleza y Salud Bebés

El proceso es iterativo para todos los elementos dentro de la página web, así mismo ir creando ramas en el sitemap. Cada elemento va a tener un ID, selector, type y el elemento que extraemos, todo esto se ve dentro de la extensión del web scraper.

Y una vez tengamos extraídos nuestros sitemaps y nuestros elementos podemos exportar esa información a un archivo csv.



### **Conclusión**

La técnica de web scraping es útil en diferentes sectores, especialmente para el mercado en línea. Esta técnica brinda beneficios a las empresas como:

- Posibilita el mejoramiento de la visibilidad de la marca en la web, gracias a la información obtenida resulta más fácil optimizar el sitio web.
- Las empresas se mantienen al tanto de los movimientos hechos por la competencia.
- Es posible que la empresa pueda saber lo que las personas dicen de la marca en los foros y redes sociales. Mejorando la interacción entre la empresa y sus clientes o potenciales clientes.
- Monitorear las tendencias y producir contenido relacionado a las mismas.

Dependiendo de quién realice esta técnica, debe cumplir con algunos requisitos para que su implementación sea totalmente legal. La más importante es que los dueños de la web que se analiza estén al tanto del scraping y que estén de acuerdo con ello.

El web scraping se utiliza para una gran variedad de tareas, por ejemplo, para recopilar datos de contacto o información especial con gran rapidez. En el ámbito profesional, el scraping se utiliza a menudo para obtener ventajas respecto a la competencia. De esta forma, por medio del harvesting de datos, una empresa puede examinar todos los productos de un competidor y compararlos con los propios. El web scraping también resulta valioso en relación con los datos financieros: es posible leer datos desde un sitio web externo, organizarlos en forma de tabla y después analizarlos y procesarlos.

Google es un buen ejemplo de web scraping. El buscador utiliza esta tecnología para mostrar información meteorológica o comparaciones de precios de hoteles y vuelos. Muchos de los portales actuales de comparación de precios también utilizan el scraping para representar información de diferentes sitios web y proveedores

# Referencias bibliográficas

https://repository.unimilitar.edu.co/bitstream/handle/10654/13220/Art%EDculo%20Metodolog%EDas%20Virtualizci%F3n%20-%20GIP.pdf?sequence=1

https://www.ionos.mx/digitalguide/paginas-web/desarrollo-web/que-es-el-web-scraping/https://www.youtube.com/watch?v=mbjZNTjHh0Y

https://bioinf.comav.upv.es/courses/linux/python/pandas.html#:~:text=pandas%20es%20un%20paquete%20de,potente%20tipo%20matricial%20a%20Python.&text=Datos%20tabulares%20con%20columnas%20de,etiquetas%20en%20columnas%20y%20filas.

https://clouding.io/hc/es/articles/360010618600-Introducci%C3%B3n-a-BeautifulSoup-4-en-Python-2#:~:text=BeautifulSoup%20es%20una%20biblioteca%20de,de%20manejar)%20de%20p%C3%A1ginas%20web.

Octoparse (2020). Herramienta de Web Scraping Gratis. https://www.octoparse.es/

https://realpython.com/python-web-scraping-practical-introduction/

https://schoolofdata.org/handbook/recipes/scraper-extension-for-chrome/?\_\_cf\_chl\_jschl\_tk\_\_=ca1df790451735cc1656b8fc477b831b3f0ad139-1612322024-0-Aei-2Qse8B0iZ1XrMRMvHD2wMxATm09S-WrCSr5ikLQ87pDGl6ajqRahnF5kuW-KRuPbpWtyWZbosa4G1yj1NvZ3CFEagzmWEUSXJfGkNGrsK20lWMEQQYsJGEMqbF33JdfHCbx5lXmZDT9LG--4s8HeCsDcuR94dk2sfryQgllbQUA0xKstuVFBVhfcmpqVtnkxvsaS1W8DzX0u8iFV8d44XpkpwgiRLf3LnynkdB3F0M5Izxb\_h\_5SrGK8\_iXGpH7lwrnlaKOCLmXeyT\_P1M24R3uj\_VycNRbB9\_Wb5B2wCcMJfP6P3kURpJjcyHErTFx5073fYnqSC5-Ky9ZevtAMbGomWmv3qnj\_Gt0Jn0wV5aFDl4jo00BYwkbJmSiuKQ

https://youtu.be/rhnMvvmfBFI

https://www.google.com.mx/amp/s/likegeeks.com/es/web-scraping-beautiful-soup-y-selenium/amp/

https://www.octoparse.com/blog/what-is-web-scraping